

## -----不确定性推理-----

### 1. 独立性、条件独立性



#### [Step 1]. Draw the ancestral graph.

根据原始概率图，构建包括表达式中包含的变量以及这些变量的ancestor节点（父节点、父节点的父节点...）的图。

#### [Step 2]. "Moralize" the ancestral graph by "marrying" the parents.

连接图中每个collider结构中的父节点，即若两个节点有同一个子节点，则连接这两个节点。（若一个变量的节点有多个父节点，则分别链接每一对父节点）。

#### [Step 3]. "Disorient" the graph by replacing the directed edges (arrows) with undirected edges (lines).

去掉图中所有的路径方向，将directional graph变为non-directional graph。

#### [Step 4]. Delete the givens and their edges.

从图中删除需要判断的概率表达式中作为条件的变量，以及和他们相连的路径。比如“是否  $P(A|BDF) = P(A|DF)?$ ”，我们删掉D, F变量以及他们的路径。

#### [Step 5]. Read the answer off the graph.

- 如果变量之间没有连接，则它们在给定条件下是独立的；
- 如果变量之间有路径连接，则它们不能保证是独立的（或者粗略地说他们是不独立的，基于概率图来说）；
- 如果其中一个变量或者两者都不包含在现在的图中（作为观测条件，在step 4 被删掉了），那么他们是独立的。

1017

赞同 52

分享

## D-separation (D 分割)

看了三个例子,我们希望确定,任意给一个有向图即贝叶斯网络我们可以得到图中任意  $A, B$  是否关于  $C$  条件独立。

定理: 在一个一般的贝叶斯网络中,  $A, B, C$  是任意的不相交结点集合, 一条路, 从集合  $A$  中的任意的结点到集合  $B$  中的任意结点, 如果出现下面的条件, 则称为被堵住 (be Blocked)

- 1) 箭头在这条路上遇见了数据集合  $C$  的结点, 并且这个结点是尾巴对尾巴 (tail-to-tail) 类型或者头对尾巴类型 (head-to-tail)
- 2) 箭头遇见了一个头对头 (head-to-head) 结点, 这个结点既不属于集合  $C$ , 这个结点的后代也不属于集合  $C$

BeHappy 周琦 <http://www.cnblogs.com/Dzhouqi/>

如果所有从  $A$  到  $B$  的路都被堵住 (Blocked), 那么就称  $A$  与  $B$  被  $C$ ,  $D$  分割了。

也可以表示为  $A \perp\!\!\!\perp B \mid C$ 。下图是关于后代, 父代的解释。

## 2. 朴素贝叶斯模型:

### 朴素贝叶斯分类器



分类任务:  $N$  种可能的类别标记  $\mathcal{Y} = \{c_1, c_2, \dots, c_N\}$ ; 要把样本  $\mathbf{x}$  分类为其中一个  
即要求: 使得后验概率  $P(c \mid \mathbf{x})$  最大的类  $c$

- $P(c \mid \mathbf{x}) = \frac{P(\mathbf{x}, c)}{P(\mathbf{x})} = \frac{P(c)P(\mathbf{x} \mid c)}{P(\mathbf{x})}$
- 假设样本集为  $D$ ,  $D_c$  为样本集中第  $c$  类样本组成的集合,
  - $P(c)$  为类别的先验概率
    - 样本空间中各类样本所占比例  $P(c) = \frac{|D_c|}{|D|}$
  - $P(\mathbf{x} \mid c)$  为样本  $\mathbf{x}$  相对于类标记  $c$  的类条件概率, 或称似然
    - 对已知类别, 假设所有属性相互独立。则:
$$P(\mathbf{x} \mid c) = \prod_{i=1}^d P(x_i \mid c) \quad \text{其中 } d \text{ 为属性数目, } x_i \text{ 为 } \mathbf{x} \text{ 在第 } i \text{ 个属性上的取值}$$
$$P(x_i \mid c) = \frac{|D_{c, x_i}|}{|D_c|} \quad \text{其中 } D_{c, x_i} \text{ 为 } D_c \text{ 中在第 } i \text{ 个属性上取值为 } x_i \text{ 的样本组成的集合。}$$
- $P(\mathbf{x})$  为用于归一化的“证据”因子,  
对于给定样本  $\mathbf{x}$ ,  $P(\mathbf{x})$  与类标记无关

25

## 拉普拉斯平滑

# 朴素贝叶斯分类器



需注意, 若某个属性值在训练集中没有与某个类同时出现过, 则直接基于式(7.17)进行概率估计, 再根据式(7.15)进行判别将出现问题。例如, 在使用西瓜数据集 3.0 训练朴素贝叶斯分类器时, 对一个“敲声=清脆”的测试例, 有

$$P_{\text{清脆}|\text{是}} = P(\text{敲声} = \text{清脆} | \text{好瓜} = \text{是}) = \frac{0}{8} = 0,$$

由于式(7.15)的连乘式计算出的概率值为零, 因此, 无论该样本的其他属性是什么, 哪怕在其他属性上明显像好瓜, 分类的结果都将是“好瓜=否”, 这显然不太合理。

为了避免其他属性携带的信息被训练集中未出现的属性值“抹去”, 在估计概率值时通常要进行“平滑”(smoothing), 常用“拉普拉斯修正”(Laplacian correction)。具体来说, 令  $N$  表示训练集  $D$  中可能的类别数,  $N_i$  表示第  $i$  个属性可能的取值数, 则式(7.16)和(7.17)分别修正为

$$\hat{P}(c) = \frac{|D_c| + 1}{|D| + N},$$
$$\hat{P}(x_i | c) = \frac{|D_{c,x_i}| + 1}{|D_c| + N_i}.$$

例如, 在本节的例子中, 类先验概率可估计为

$$\hat{P}(\text{好瓜} = \text{是}) = \frac{8+1}{17+2} \approx 0.474, \quad \hat{P}(\text{好瓜} = \text{否}) = \frac{9+1}{17+2} \approx 0.529$$

类似地,  $P_{\text{青绿}|\text{是}}$  和  $P_{\text{青绿}|\text{否}}$  可估计为

$$\hat{P}_{\text{青绿}|\text{是}} = \hat{P}(\text{色泽} = \text{青绿} | \text{好瓜} = \text{是}) = \frac{3+1}{8+3} \approx 0.364,$$

优缺点: 受限于独立性的假设, 且无法处理小数据集情况。

## 朴素贝叶斯分类器的优劣



- **优势:**
  - 在**大型数据集**上**非常容易实现**并获得非常好的结果。
  - 它具有**很好的计算效率**。与复杂算法相比, 假设所有特征都是独立的朴素贝叶斯算法非常快。在某些情况下, 我们会偏好速度甚于精度。
  - 它还可以用于**预测多个类别**。
  - 它还可以用于自然语言处理中的**文本分类**。
- **劣势:**
  - 关于**特征独立**的强假设, 这在**现实生活**的应用程序中**几乎不成立**。
  - 在**数据集较小时**, 它的**精度值会下降**。
  - 当目标是**预测概率**而不是分类时, 该方法提供非常有**偏见的结果**。

33

### 3. 贝叶斯网络

(1) 基本术语: BN, CPT

(2) 1. 贝叶斯网络的本质:

是一种数据结构, 用来表示变量之间的依赖关系, 可以表示任何完全联合概率分布。

2. 组成:

- 节点：对应一个随机变量，也会包含一个条件概率表，条件概率表中的每一行可能对应一个事件，那我们想要某个事件的概率，则可利用条件概率表来求
- 边：表示依赖关系

### 3. 构造贝叶斯网络：

- 将变量排序，使其有一定拓扑结构，尽量保持因果顺序
- 选择父节点，插入边
- 记录条件概率表

### 4. 条件独立性：

- 给定父节点，其独立于所有非子孙节点
- 给定马尔科夫覆盖（父节点，子节点，子节点的父节点），独立于所有其他变量。

### 5. 精确推断：通过贝叶斯网络求得事件发生的概率，往往包含证据变量和查询变量，计算给定证据变量，求查询变量的后验概率分布。

### 6. 如何精确推断：

- 枚举
- 变量消元算法
- 将变量排序以减少复杂度
- 聚类以减少复杂度（较为困难）

### 7. 近似推理：采用近似的方法求得所需事件发生概率，实际上是在使用蒙特卡洛算法进行随机采样

- 直接采样法：按照拓扑顺序依次采样每个变量
- 拒绝采样：先在指定先验概率中生产样本，然后删掉与证据不匹配的样本
- 重要性采样（似然加权）：也是先按拓扑排序采样变量，当遇到证据变量时，权重乘上在给定其父变量之后的条件概率
- 吉布斯采样：从任意一个状态出发，通过为非证据变量采样一个值来生成下一个状态。

## 4. 时序概率推理

### （1）基本概念：

转移模型和传感器模型，一阶二阶马尔科夫过程

14-2 描述雨伞世界的贝叶斯网络结构与条件分布。转移模型是  $P(Rain_t | Rain_{t-1})$ ,  $P(Umbrella_t | Rain_t)$

指定转移模型和传感器模型之外，我们还需要说明事物的初始状态分布  $P(X_0)$ 。这样一来，我们可以利用式 (13-2) 得到所有变量的完整时间步  $t$ ,

$$P(X_{0:t}, E_{1:t}) = P(X_0) \prod_{i=1}^t P(X_i | X_{i-1}) P(E_i | X_i)$$

项分别是初始状态模型  $P(X_0)$ 、转移模型  $P(X_i | X_{i-1})$  和传感器模型

(2) 时序模型中的推断：

- 滤波：给定至今为止 (0-t) 所有证据，求t时刻变量X后验概率
- 预测：给定至今为止 (0-t) 所有证据，求未来K天后变量X后验概率
- 平滑：给定至今为止 (0-t) 所有证据，求过去第K天， $K < t$  的变量X后验概率
- 最可能解释：给定至今为止 (0-t) 所有证据，找到最有可能产生这些证据的状态序列，即  $X_{0-t}$ 。（有个微比特算法）
- 学习（当不知道转移模型和传感器模型时，可以从观测中学习）

(3) 隐马尔科夫模型：要求过程状态由单个离散随机变量描述，对证据变量没有要求


(4) 卡尔曼滤波：处理连续状态变量

(5) 动态贝叶斯网络：每个时间片可以有任意数量的状态变量和证据变量，其与HMM的区别在于他可以将复杂系统的状态分解为其组成变量，以利用时序概率模型中的稀疏性。

- 精确推理：变量消元法，分为在线和离线方式



- 变量消元法可以应用到 DBNs的精确推理
- 离线方式: “展开” (摊开)  $T$  个时间步的贝叶斯网络,  
然后用贝叶斯网络精确推理中的变量消元法求  $P(X_T | e_{1:T})$



例:给定各个Evidences  
和贝叶斯网络, 求确切  
的 $G_3^b$

- 在线方式: 消除前一时间步的所有变量, 仅存储当前时间步的因子
- 问题: 最大因子包含当前时间步的所有变量, 复杂度仍是变量个数的指数级

31

- 近似推理: 粒子滤波
  - 两个创新点: 使用样本本身作为当前状态分布的近似表示, 聚焦与状态空间的高概率区域上的样本集合
  - 步骤: 预测、更新权值、重采样